

# אופטימליזציה התאמה הכ"ף

גרדיינט עבור דאטא-סט (נתונים)  $D$

בחינה הקלאסית מנסים למצוא את הפונקציה  $\theta$

שממנה פונקציה הסדירה  $\hat{\theta} = \underset{\theta}{\operatorname{argmin}} L(\theta, D)$

בחינה הכ"ף מנסים למצוא הרפואה על פני

$\theta$  בהינתן  $D \leftarrow P(\theta | D)$

דוגמה - עבור 1000 נתונים  $D = \{x_i\} = (0, 1, 1, 0, \dots)$

רובם 0 - 3 אף אפלי"ם

1)  $\hat{\theta}_{MLE}(x) = \frac{n_0}{1000}$

2)  $\hat{\theta}_2(x) = \frac{\sum_{i=1}^{10} x_i}{1000}$

3) דגם נייבית עם 20 גורמים קורבולוציה ולבנה  
fully-connected

ב-3. למדוד את הזאת האזוריים, אפשר להשתמש ב- $BMSE(\hat{\theta})$  (Bayesian mean squared error)

$$BMSE(\hat{\theta}) = E_{\theta^{GT}, D} \|\hat{\theta}(D) - \theta^{GT}\|^2$$

$$= \int_{\theta^{GT}, D} P(\theta, D) \|\hat{\theta}(D) - \theta^{GT}\|^2 d\theta dD$$

בתנאים:

$$\left. \begin{array}{l} (1) \text{ נזכר } \theta^{GT} \text{ לפי } P(\theta) \\ (2) \text{ נזכר } D \text{ לפי } P(D|\theta^{GT}) \\ (3) \text{ נחשב } \|\hat{\theta}(D) - \theta^{GT}\|^2 \end{array} \right\} \begin{array}{l} \text{נמצא את } \\ \text{במקום פתוח} \\ \text{ונחשב מחזור}$$

חלופה: האזוריים  $\hat{\theta}(x) = E(\theta|x)$  הוא האזוריים

האופטימלי מבחינת  $BMSE$

$$E(\theta|x) = \int_{\theta} \theta \cdot P(\theta|x) d\theta$$

הוכחה -

$$BMSE = E_{\theta, D} \|\hat{\theta}(D) - \theta\|^2$$

$$= \int_{\theta, D} P(\theta, D) \cdot \|\hat{\theta}(D) - \theta\|^2 d\theta dD$$

$$= \int_{\theta, D} P(D) \cdot P(\theta|D) \cdot \|\hat{\theta}(D) - \theta\|^2 d\theta dD$$

$$= \int_D P(D) \cdot \int_{\theta} P(\theta|D) \cdot \|\hat{\theta}(D) - \theta\|^2 d\theta dD$$

נראה שלא  $D$  אנחנו בוחרים באופטימיזציה של  $BMSE$ .  
כי כן צריך לזכור שיש לנו גם  $D$  הממוצע של  $D$

נזכור כי  $C(\hat{\theta}, D)$  לא תלוי ב- $\theta$  ולכן נגזיר לפי  $\theta$

$$\frac{\partial C}{\partial \hat{\theta}} = \int_{\theta} P(\theta|D) \cdot 2(\hat{\theta}(D) - \theta) d\theta$$

נשווה לאפס -

$$2 \cdot \int_{\theta} P(\theta|D) \cdot \hat{\theta}(D) d\theta - 2 \cdot \int_{\theta} P(\theta|D) \cdot \theta d\theta = 0$$

$$\int_{\theta} P(\theta|D) \hat{\theta}(D) d\theta = \int_{\theta} P(\theta|D) \theta d\theta$$

$\hat{\theta}(D)$   $E(\theta|D)$

$$P(\theta) = \begin{cases} 1 & \theta \in [0,1] \\ 0 & \text{else} \end{cases} \quad \text{ולכן } \theta \sim U[0,1] \text{ - פונקציית צפיפות אחידה}$$

$$P(D|\theta) = \prod_{i=1}^{1000} \begin{cases} \theta & x_i=0 \\ 1-\theta & x_i=1 \end{cases} = \theta^{n_0} \cdot (1-\theta)^{n_1}$$

$$P(\theta|D) = \frac{P(D|\theta)}{P(D)} \cdot P(\theta) = \frac{\theta^{n_0} (1-\theta)^{n_1}}{\int_{\theta} \theta^{n_0} (1-\theta)^{n_1} d\theta}$$

ולחשוב היחס

$$E(\theta|D) = \int \theta \cdot P(\theta|D) d\theta$$

$$= \int_{\theta} \theta \cdot \frac{\theta^{n_0} (1-\theta)^{n_1}}{\int_{\theta} \theta^{n_0} (1-\theta)^{n_1} d\theta} d\theta$$

בקטע לא מקרי, פאנאקטור קטן, למשל  
בשני הפאקטור ציביליזציה.

הפאקטור ציביליזציה - על ווקטור הסמפלים (ווקטור  $\theta$  של  
א'קטור חוקים אוכלוס (הא'קטור  $\theta$ ).

ההפאקטור  $\theta \sim \text{Dirichlet}(\alpha)$  מוזנח אף

$$P(\theta) = \frac{1}{B(\alpha)} \cdot \prod_k \theta_k^{\alpha_k - 1}$$

$$B(\alpha) := \frac{\prod_k \Gamma(\alpha_k)}{\Gamma(\alpha_0)} \quad \alpha_0 := \sum_k \alpha_k \quad \text{כאשר}$$

$$E(\theta_k) = \frac{\alpha_k}{\alpha_0} \quad \text{המחלף של } \theta_k \text{ הינו}$$

צד 3

(1)  $\alpha = (1, 1, 1, 1)$  (המפלגות זונ' פורמט משה הם מפלגות)

$$P(\theta) = \frac{1}{B(\alpha)} \cdot \prod_k \theta_k^{\alpha_k} = \frac{1}{B(\alpha)} \cdot 1$$

$$P(\theta) = \frac{1}{B(\alpha)} \cdot \prod_k \theta_k^{10^6} \quad \alpha = (10^6, 10^6, \dots, 10^6) \quad (2)$$

בהמשך, אם אחר הקוארינטל של  $\theta$  שונה

מ-1 ההסתברות היא פרוקטור 0.

נחזור לחישוב של  $P(\theta|D)$  נסמן  $\theta = \theta_0$ ,  $(1-\theta) = \theta_1$

$$P(\theta|D) = \frac{\theta^{h_0} (1-\theta)^{h_1}}{\int_{\theta^0} \theta^{h_0} (1-\theta)^{h_1} d\theta} = \frac{1}{B} \cdot \theta^{h_0} \cdot \theta_1^{h_1}$$

כלומר מצאנו ל-  $\theta|D \sim \text{Dirichlet}(h_0+1, h_1+1)$

$$E(\theta|D) = \left( \frac{h_0+1}{2}, \frac{h_1+1}{2} \right) \quad \text{ולפי המפלגות ה"ל מצאנו}$$

$$P(\theta|D) = \frac{P(\theta) \cdot P(D|\theta)}{P(D)}$$

הצגה

$P(\theta)$  - "Prior Probability"

$P(D|\theta)$  - "Likelihood"

$P(D)$  - "Evidence"

$P(\theta|D)$  - "Posterior Probability"

$\hat{\theta}^{MMSE}(D) = E(\theta|D)$  - אומדן הממוצע

$\hat{\theta}^{MAP}(D) = \arg\max_{\theta} P(\theta|D)$  - "Maximum a posteriori"

$\hat{\theta}^{MLE}(D) = \arg\max_{\theta} P(D|\theta)$  - "Maximum Likelihood Estimator"

Conjugate Prior

אם  $P(\theta|D)$  שייך לאותה משפחה פונקציונלית כמו  $P(\theta)$ ,

$P(\theta)$  נקראת Conjugate prior (פונקציה צמודה)

$P(D|\theta)$

דוגמה - אם  $P(\theta|D)$  היא פונקציה גאוסית, אז  $P(\theta)$  צריכה

היא CP  $P(D|\theta)$